

Projektbericht

In diesem Projekt wurde ein Convolutional Neural Network (CNN) zur binären Bildklassifikation entwickelt. Ziel war es, Bilder automatisch in zwei Klassen zu unterscheiden: **no_zebra** und **zebra**. Dafür wurde zuerst ein Baseline-Modell trainiert und anschliessend ein optimiertes CNN-Modell entwickelt. Die Ergebnisse wurden mit verschiedenen Kennzahlen ausgewertet und im Ordner **outputs** gespeichert.

Der Datensatz besteht aus Trainings, Validierungs und Testdaten. Alle Bilder wurden auf eine Grösse von **160 × 160 Pixeln** skaliert. Die Batch Size betrug **32**. Die Klassenverteilung zeigt, dass der Datensatz unausgeglichen ist. Im Training gibt es **5405 Bilder der Klasse no_zebra** und **1059 Bilder der Klasse zebra**. In den Validierungsdaten sind es **1158 no_zebra** und **226 zebra**, im Testdatensatz **1159 no_zebra** und **228 zebra**. Damit kommt die Klasse no_zebra deutlich häufiger vor als die Klasse zebra. Das Verhältnis im Training beträgt ungefähr **5.10 : 1**. Deshalb ist neben der Accuracy besonders der Recall und der F1-Score der Klasse zebra wichtig.

Als erstes wurde ein Baseline-CNN für **20 Epochen** trainiert. Das Modell erreichte auf den Testdaten eine Accuracy von **0.8659** und einen Loss von **0.3028**. Die Precision lag bei **0.8750**, der Recall jedoch nur bei **0.2149**. Der F1-Score der Klasse zebra betrug **0.3451**. Die Confusion Matrix zeigt, dass das Modell **1152 no_zebra-Bilder** korrekt erkannte, aber nur **49 zebra-Bilder** richtig klassifizierte. Gleichzeitig wurden **179 zebra-Bilder** fälschlicherweise als no_zebra eingestuft. Dadurch wurde deutlich, dass das Baseline-Modell zwar eine relativ hohe Accuracy erreicht, die Minderheitsklasse zebra aber schlecht erkennt.

Aus diesem Grund wurde das Modell optimiert. Die Optimierung war notwendig, weil der Datensatz unausgeglichen ist und der Recall der Klasse zebra im Baseline-Modell sehr niedrig war. Mögliche Massnahmen waren unter anderem Early Stopping, Anpassung der Lernrate, Class Weights und eine verbesserte Modellarchitektur. Das optimierte CNN wurde für **40 Epochen** trainiert.

Das optimierte Modell erzielte deutlich bessere Ergebnisse. Auf den Testdaten erreichte es eine Accuracy von **0.9712**, einen Loss von **0.0997**, eine Precision von **0.9747** und einen Recall von **0.8465**. Der F1-Score der Klasse zebra stieg auf **0.9061**. Auch die Confusion Matrix verbesserte sich deutlich: **1154 no_zebra-Bilder** und **193 zebra-Bilder** wurden korrekt erkannt. Nur noch **35 zebra-Bilder** wurden falsch als no_zebra klassifiziert.

Der Vergleich zeigt, dass das optimierte Modell dem Baseline-Modell klar überlegen ist. Besonders wichtig ist die Verbesserung des Recalls und des F1-Scores, weil dadurch die Klasse zebra viel zuverlässiger erkannt wird. Die Accuracy allein wäre bei diesem unausgeglichenen Datensatz nicht ausreichend gewesen, um die Modellqualität richtig zu bewerten.

Persönlich habe ich aus dem Projekt gelernt, dass bei unausgeglichenen Datensätzen nicht nur die Accuracy betrachtet werden darf. Ein Modell kann eine hohe Accuracy erreichen und trotzdem die kleinere Klasse schlecht erkennen. Deshalb sind Precision, Recall, F1-Score und die Confusion Matrix sehr wichtig. Insgesamt zeigt das Projekt, dass CNNs für Bildklassifikation gut geeignet sind, aber durch geeignete Optimierung deutlich verbessert werden können.